Exploració de les dades

Descripció

 Familiaritza't amb les tècniques d'exploració de les dades mitjantçant la estructura de dades, Dataframe amb la llibreria Pandas.

NIVELL 1

Exercici 1

Descarrega el data set Airlines Delay: Airline on-time statistics and delay causes i carrega'l a un pandas Dataframe. Explora les dades que conté, i queda't únicament amb les columnes que consideris rellevants.

```
In [10]:
         # Crido a les llibreries de pandas i matplotlib i numpy per poder tregballar tranquilament
         # Faig entrar l'arxiu CSV gràcies a pandas
         import pandas as pd
         import matplotlib.pyplot as plt
         import numpy as np
         delayedFlights = pd.read csv(r'C:\Users\Anna\DataScience\SPRINTS\SPRINT 2\Sprint2 T05\Dela
         delayedFlights[:]
```

Out[10]:

	Unnamed: 0	Year	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	Uniqu
0	0	2008	1	3	4	2003.0	1955	2211.0	2225	
1	1	2008	1	3	4	754.0	735	1002.0	1000	
2	2	2008	1	3	4	628.0	620	804.0	750	
3	4	2008	1	3	4	1829.0	1755	1959.0	1925	
4	5	2008	1	3	4	1940.0	1915	2121.0	2110	
•••										
1936753	7009710	2008	12	13	6	1250.0	1220	1617.0	1552	
1936754	7009717	2008	12	13	6	657.0	600	904.0	749	
1936755	7009718	2008	12	13	6	1007.0	847	1149.0	1010	
1936756	7009726	2008	12	13	6	1251.0	1240	1446.0	1437	
1936757	7009727	2008	12	13	6	1110.0	1103	1413.0	1418	

1936758 rows × 30 columns

```
In [11]:
          # Primer vull saber la mida de la taula (files, columnes)
         print (delayedFlights.shape)
```

(1936758, 30)

```
In [12]:
```

Imprimeixo la funció info per saber de què està compost el dataframe

```
delayedFlights.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 1936758 entries, 0 to 1936757
        Data columns (total 30 columns):
         # Column
                              Dtype
        ____
                              ____
         0
           Unnamed: 0
                              int64
         1
            Year
                              int64
         2
           Month
                              int64
         3 DayofMonth
                              int64
         4 DayOfWeek
                              int64
         5 DepTime
                              float64
                             int64
         6 CRSDepTime
         7
            ArrTime
                              float64
         8 CRSArrTime
                              int64
           UniqueCarrier
                             object
         10 FlightNum
                             int64
         11 TailNum
                             object
         12 ActualElapsedTime float64
         13 CRSElapsedTime float64
         14 AirTime
                              float64
         15 ArrDelay
                             float64
         16 DepDelay
                              float64
         17 Origin
                             object
         18 Dest
                              object
         19 Distance
                             int64
         20 TaxiIn
                              float64
         21 TaxiOut
                             float64
         22 Cancelled
                              int64
         23 CancellationCode object
                             int64
         24 Diverted
         25 CarrierDelay
                             float64
         26 WeatherDelay
                             float64
         27 NASDelay
                              float64
         28 SecurityDelay float64
        29 LateAircraftDelay float64
        dtypes: float64(14), int64(11), object(5)
        memory usage: 443.3+ MB
In [13]:
         # Aquesta funció ens ajuda a imprimir només els noms de les columnes per visualitzar si he
        delayedFlights.columns
         # El nom que canviaria aquí seria el primer, unnamed: 0 , però com que la vull eliminar me
        Index(['Unnamed: 0', 'Year', 'Month', 'DayofMonth', 'DayOfWeek', 'DepTime',
Out[13]:
               'CRSDepTime', 'ArrTime', 'CRSArrTime', 'UniqueCarrier', 'FlightNum',
               'TailNum', 'ActualElapsedTime', 'CRSElapsedTime', 'AirTime', 'ArrDelay',
               'DepDelay', 'Origin', 'Dest', 'Distance', 'TaxiIn', 'TaxiOut',
               'Cancelled', 'CancellationCode', 'Diverted', 'CarrierDelay',
               'WeatherDelay', 'NASDelay', 'SecurityDelay', 'LateAircraftDelay'],
              dtype='object')
In [14]:
         #Ara vull saber si els valors d'alguna columna són TOTS Nuls, cosa que no m'aportarien cal
        print(delayedFlights.isnull())
        print("
                                                                                        ")
        print(delayedFlights.count())
        print ("Si hi ha un total de 1936758 files amb informació, les columnes que no coincideixi
        print("
         print(delayedFlights.isnull().sum())
```

	Unnamed: 0	Year	Month	DavofMont	h Da	vOfWeek	DenTime	CRSDepTime	٠ ,
0	False		False	Fals		False	False	_	
			False	Fals					
1	False					False	False		
2	False		False	Fals		False	False		
3	False		False	Fals		False	False		
4	False	e False	False	Fals	se	False	False		
• • •			• • •			• • •	• • •		
1936753	False		False	Fals		False	False		
1936754	False		False	Fals	se	False	False	False	9
1936755	False	e False	False	Fals	se	False	False	False	9
1936756	False	False	False	Fals	e	False	False	False)
1936757	False	False	False	Fals	se	False	False	False	€
	ArrTime C	CRSArrTime	e Uniqu	ueCarrier		TaxiIn	TaxiOut	Cancelled	\
0	False	False	е	False		False	False	False	
1	False	False	е	False		False	False	False	
2	False	False	е	False		False	False	False	
3	False	False		False		False	False		
4	False	False		False		False	False		
1936753	False	False		False		False	False		
1936754	False	False		False		False	False		
1936755									
	False	False		False	• • •	False	False		
1936756	False	False		False	• • •	False	False		
1936757	False	False	е	False		False	False	False	
	Cancellati	on Codo	Dimorto	d Carriar	-Dolass	Months	~Dolass	MACDoloss \	
0	Cancellati			d Carrier	_		_	NASDelay \	
0		False	False		True		True	True	
1		False	False		True		True	True	
2		False	False		True		True	True	
3		False	False		False		False	False	
4		False	False		True		True	True	
			• • •					• • •	
1936753		False	False		False		False	False	
1936754		False	False		False		False	False	
1936755		False	False		False		False	False	
1936756		False	False	9	True		True	True	
1936757		False	False	9	True		True	True	
	SecurityDe	elay Late	eAircraf	ftDelay					
0	T	rue		True					
1	I	rue		True					
2	T	rue		True					
3	Fa	alse		False					
4	T	rue		True					
1936753	Fa	alse		False					
1936754	Fa	alse		False					
1936755	Fa	alse		False					
1936756		rue		True					
1936757		rue!		True					
1300.0.	_	- 1 4 0		1140					
[1936758	rows x 30	columns]							
Unnamed:		193675	Ω						
	U								
Year		193675							
Month	+ h	193675							
DayofMon		193675							
DayOfWee	ВK	193675							
DanTima		193675	×						

DepTime

ArrTime

CRSDepTime

1936758

1936758

1929648

CRSArrTime	1936758
UniqueCarrier	1936758
FlightNum	1936758
TailNum	1936753
ActualElapsedTime	1928371
CRSElapsedTime	1936560
AirTime	1928371
ArrDelay	1928371
DepDelay	1936758
Origin	1936758
Dest	1936758
Distance	1936758
TaxiIn	1929648
TaxiOut	1936303
Cancelled	1936758
CancellationCode	1936758
Diverted	1936758
CarrierDelay	1247488
WeatherDelay	1247488
NASDelay	1247488
SecurityDelay	1247488
LateAircraftDelay	1247488
-11 ' - 1 C A	

dtype: int64

Si hi ha un total de 1936758 files amb informació, les columnes que no coincideixin amb aq uest número vol dir que tenen valors nul·ls, les quals les hauria d'estudiar més d'aprop d e per què són nuls

Unnamed: 0	0								
Year	0								
Month	0								
DayofMonth	0								
DayOfWeek	0								
DepTime	0								
CRSDepTime	0								
ArrTime	7110								
CRSArrTime	0								
UniqueCarrier	0								
FlightNum	0								
TailNum	5								
ActualElapsedTime	8387								
CRSElapsedTime	198								
AirTime	8387								
ArrDelay	8387								
DepDelay	0								
Origin	0								
Dest	0								
Distance	0								
TaxiIn	7110								
TaxiOut	455								
Cancelled	0								
CancellationCode	0								
Diverted	0								
CarrierDelay	689270								
WeatherDelay	689270								
NASDelay	689270								
SecurityDelay	689270								
LateAircraftDelay	689270								
dtype: int64									
A simple wists nod	lria elimina:	r alminae	columnae	alle no	o m	dinan	rac	on	auant

A simple vista, podria eliminar algunes columnes que no em diuen res en quant als retards dels vols, com per exemple l'any, ja que tots els vols són del 2008, la columna Unnamed, ja que tinc el número de vol que em pot fer la mateixa funció, etc.

```
delayedFlights = delayedFlights.drop(['Unnamed: 0', 'Year', 'Cancelled', 'CancellationCode
print(delayedFlights)
```

	Month I	DayofMonth	DayOf	Week	DepTi	me C	RSDepTime	ArrT	ime	\		
0	1	3		4	2003	. 0	1955	221	1.0			
1	1	3		4	754	.0	735	100	2.0			
2	1	3		4	628	.0	620	80	4.0			
3	1	3		4	1829	. 0	1755	195	9.0			
4	1	3		4	1940		1915	212				
1936753	12	13		6	1250	. 0	1220	161	7.0			
1936754	12	13		6	657	.0	600	90	4.0			
1936755	12	13		6	1007	.0	847	114	9.0			
1936756	12	13		6	1251	.0	1240	144	6.0			
1936757	12	13		6	1110	.0	1103	141	3.0			
	ana m'	** '		-1.	1		1.01	1m '		`		
0		.me Unique(F.T.T		Act	ualElapsed		• • •	\		
0		225	WN		335			L28.0	• • •			
1		000	WN		3231			L28.0	• • •			
2		750	WN		448			96.0	• • •			
3		925	WN		3920			90.0	• • •			
4	21	.10	WN		378]	101.0	• • •			
			• • •						• • •			
1936753		552	DL		1621			L47.0	• • •			
1936754		749	DL		1631			L27.0	• • •			
1936755		10	DL		1631			162.0	• • •			
1936756		137	DL		1639			L15.0	• • •			
1936757	14	118	DL		1641		1	123.0				
	DepDelay	v Origin	Dest I	Dista	nce Di	verte	d CarrierI	Delav	Weat	therDe	elav	\
0	8.0		TPA		810		0	NaN			NaN	,
1	19.0		TPA		810		0	NaN			NaN	
2	8.0		BWI		515		0	NaN			NaN	
3	34.0		BWI		515		0	2.0			0.0	
4	25.0		JAX		688		0	NaN			NaN	
							•					
1936753	30.0) MSP	ATL		906		0	3.0			0.0	
1936754	57.0	RIC	ATL		481		0	0.0		1	57.0	
1936755	80.0	ATL	IAH		689		0	1.0			0.0	
1936756	11.0) IAD	ATL		533		0	NaN			NaN	
1936757	7.0	SAT	ATL		874		0	NaN			NaN	
	NACDal	y Security	*Dola	T a + a	7 1 2 2 2 2	f+Dal	277					
0	NASDelay	_	_	шате.	Aircra		_					
0	NaN		NaN				aN					
1	NaN		NaN				aN					
2	NaN		NaN				aN					
3	0.0		0.0			32						
4	NaN 		NaN 				aN 					
1936753	0.0		0.0			22						
1936754	18.0		0.0				.0					
1936755	19.0		0.0			79						
1936756	NaN		NaN				aN					
1936757	NaN		NaN				aN					
[1026750												

[1936758 rows x 23 columns]

In [25]:


En els següents punts, faig alguns plots per practicar i veure una mica com va funciona:

In [26]:

delayedFlights['Month'].plot()


[#] He eliminat 7 columnes que crec que no les necessitaré.

Out[26]: <AxesSubplot:> 12 10 8 6 4 2 0.25 0.50 0.75 1.00 1.25 1.50 1.75 2.00 0.00 le6 In [27]: delayedFlights['Distance'].plot() <AxesSubplot:> Out[27]: 5000 4000 3000 2000



```
In [28]:
         delayedFlights['CarrierDelay'].plot()
```


<AxesSubplot:> Out[28]:




```
In [102...
          delayedFlights['LateAircraftDelay'].plot()
          delayedFlights.plot(kind = "scatter", y = "LateAircraftDelay",
```

<AxesSubplot:xlabel='Month', ylabel='LateAircraftDelay'>

Out[102...





Exercici 2

Fes un informe complet del data set:

- Resumeix estadísticament les columnes d'interès
- Troba quantes dades faltants hi ha per columna
- Crea columnes noves (velocitat mitjana del vol, si ha arribat tard o no...)
- Taula de les aerolínies amb més endarreriments acumulats
- Quins són els vols més llargs? I els més endarrerits?
- Etc.

In [57]:

Imprimeixo les dades bàsiques que em fa la funció describe()
delayedFlights.describe()

Out[57]:		Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	Fligh
	count	1.936758e+06	1.936758e+06	1.936758e+06	1.936758e+06	1.936758e+06	1.929648e+06	1.936758e+06	1.93675
	mean	6.111106e+00	1.575347e+01	3.984827e+00	1.518534e+03	1.467473e+03	1.610141e+03	1.634225e+03	2.18426
	std	3.482546e+00	8.776272e+00	1.995966e+00	4.504853e+02	4.247668e+02	5.481781e+02	4.646347e+02	1.94470
	min	1.000000e+00	1.000000e+00	1.000000e+00	1.000000e+00	0.000000e+00	1.000000e+00	0.000000e+00	1.00000

```
25% 3.000000e+00 8.000000e+00
                                                                      2.000000e+00 1.203000e+03 1.35000e+03 1.316000e+03 1.325000e+03
                                                                                                                                                                                                                    6.10000
 50% 6.000000e+00 1.600000e+01 4.000000e+00 1.545000e+03 1.510000e+03 1.715000e+03 1.705000e+03 1.54300
 75%
           9.000000e+00 2.300000e+01 6.000000e+00 1.900000e+03 1.815000e+03 2.030000e+03 2.014000e+03 3.42200
           1.200000e + 01 \quad 3.100000e + 01 \quad 7.000000e + 00 \quad 2.400000e + 03 \quad 2.359000e + 03 \quad 2.400000e + 03 \quad 2.40
 # Imprimeixo la correlació que em fa la funció corr()
delayedFlights.corr()
                     limit_output extension: Maximum message size of 10000 exceeded with 11487 characters
  In [84]:
                         Resto hora prevista d'arribada amb hora d'arribada real per veure si hi ha
                        hagut retard o no, si el resultat és negatiu, vol dir que no hi ha hagut
                        retard, i si és positiu és que sí que hi ha hagut retard
                         retard = np.subtract(delayedFlights.ArrTime , delayedFlights.CRSArrTime)
                        print(retard)
                        print("El retard més gran va ser de", retard.max(), "minuts, és a dir, de", retard
                         .max()/60, "h.")
                         # No sé si és possible un retard tant gran o estic fent alguna cosa malament, pots
                        er per alguna cosa climàtica que es tanquéssin aeroports
0
                           -14.0
1
                                2.0
2
                             54.0
3
                             34.0
4
                             11.0
1936753
                             65.0
                           155.0
1936754
1936755
                           139.0
1936756
                                9.0
1936757
                             -5.0
Length: 1936758, dtype: float64
El retard més gran va ser de 2399.0 minuts, és a dir, de 39.983333333333334 h.
                        # Inserto el resultat "TotalDelay" al dataframe principal
                        delayedFlights1 = delayedFlights.assign(totalTimeDelayed = retard).values)
ValueError
                                                                                                        Traceback (most recent call last)
~\AppData\Local\Temp/ipykernel_18968/4276466275.py in <module>
               3 #df1.assign(e=pd.Series(np.random.randn(sLength)).values)
---> 4 delayedFlights1 = delayedFlights.assign(totalTimeDelayed = pd.Series(np.subtrac
t(totalDelay = [delayedFlights.ArrTime , delayedFlights.CRSArrTime])).values)
ValueError: invalid number of arguments
  In [85]:
```

Faig un true/false per després fer un contador en bucle per saber quants vols

hi ha hagut en retard

DayofMonth

Month

In [58]:

Out[58]:

DayOfWeek

CRSDepTime

DepTime

ArrTime

CRSArrTime

Fligh


```
condicio = (retard[:] > 0)
          print(condicio)
0
           False
1
            True
2
            True
3
            True
4
            True
           . . .
1936753
            True
1936754
           True
1936755
            True
           True
1936756
           False
1936757
Length: 1936758, dtype: bool
          1.1.1
In [88]:
          contador = retard.apply(
              lambda x: True if x[1] > 0 else False)
          numeroRetards = len(contador[contador == True].index)
          print(numeroRetards)
          contador = 0
          for x in range(len(retard)):
              if retard.iloc[1,:]:
                  contador +=1
          print(contador)
          index, counts = np.unique(
              retard.to_numpy(),
              return_counts=True
          suma = retard.Series(counts, index)
KeyError
                                            Traceback (most recent call last)
~\AppData\Local\Temp/ipykernel_18968/1283071686.py in <module>
     22 suma = retard.Series(counts, index)
     23 '''
---> 24 suma= retard["True"].sum(axis=1)
~\anaconda3\lib\site-packages\pandas\core\series.py in __getitem__(self, key)
    940
    941
                elif key_is_scalar:
--> 942
                     return self._get_value(key)
    943
    944
                if is_hashable(key):
~\anaconda3\lib\site-packages\pandas\core\series.py in _get_value(self, label, takeabl
e)
   1049
```


1.1.1


```
1050
                # Similar to Index.get_value, but we do not fall back to positional
-> 1051
                loc = self.index.get_loc(label)
   1052
                return self.index._get_values_for_loc(self, loc, label)
   1053
~\anaconda3\lib\site-packages\pandas\core\indexes\range.py in get_loc(self, key, metho
d, tolerance)
    386
                        except ValueError as err:
    387
                            raise KeyError(key) from err
--> 388
                    raise KeyError(key)
    389
                return super().get_loc(key, method=method, tolerance=tolerance)
    390
KeyError: 'True'
  In [ ]:
         Exercici 3
         Exporta el data set net i amb les noves columnes a Excel.
 In [101... | # determining the name of the file
          docExcel = 'TotalDelayedTime.xlsx'
          # saving the excel
          delayedFlights.to_excel(docExcel)
ValueError
                                           Traceback (most recent call last)
~\AppData\Local\Temp/ipykernel_18968/3528203272.py in <module>
      4 # saving the excel
---> 5 delayedFlights.to_excel(docExcel)
~\anaconda3\lib\site-packages\pandas\core\generic.py in to_excel(self, excel_writer, sh
eet name, na rep, float format, columns, header, index, index label, startrow, startco
1, engine, merge_cells, encoding, inf_rep, verbose, freeze_panes, storage_options)
   2282
                    inf_rep=inf_rep,
   2283
                )
                formatter.write(
-> 2284
   2285
                    excel_writer,
   2286
                    sheet_name=sheet_name,
~\anaconda3\lib\site-packages\pandas\io\formats\excel.py in write(self, writer, sheet_n
ame, startrow, startcol, freeze_panes, engine, storage_options)
    821
                num_rows, num_cols = self.df.shape
    822
                if num_rows > self.max_rows or num_cols > self.max_cols:
--> 823
                    raise ValueError(
    824
                        f"This sheet is too large! Your sheet size is: {num_rows}, {num
_cols} "
    825
                        f"Max sheet size is: {self.max_rows}, {self.max_cols}"
ValueError: This sheet is too large! Your sheet size is: 1936758, 23 Max sheet size is:
```


1048576, 16384


IMATGES STRING3














In []:

	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	FlightNum
Month	1.000000	0.059651	0.000088	-0.007809	-0.011367	0.001014	0.001367	-0.000188
DayofMonth	0.059651	1.000000	0.017476	0.001014	0.001019	0.000833	0.000758	-0.005912
DayOfWeek	0.000088	0.017476	1.000000	0.021924	0.027039	0.010913	0.017750	-0.009769
DepTime	-0.007809	0.001014	0.021924	1.000000	0.881598	0.458934	0.711513	-0.024786
CRSDepTime	-0.011367	0.001019	0.027039	0.881598	1.000000	0.396724	0.710303	-0.054808
ArrTime	0.001014	0.000833	0.010913	0.458934	0.396724	1.000000	0.619385	-0.013665
CRSArrTime	0.001367	0.000758	0.017750	0.711513	0.710303	0.619385	1.000000	-0.060006
FlightNum	-0.000188	-0.005912	-0.009769	-0.024786	-0.054808	-0.013665	-0.060006	1.000000
ActualElapsedTime	0.002684	-0.000880	0.003072	-0.047040	-0.034925	-0.013595	0.033203	-0.322283
CRSElapsedTime	0.007046	-0.000028	0.004954	-0.044619	-0.026388	-0.012911	0.040117	-0.335956
AirTime	0.000860	-0.000244	0.004738	-0.054831	-0.036582	-0.017684	0.025907	-0.341250
ArrDelay	-0.000897	0.004129	0.006123	0.127017	0.044447	-0.050948	0.043078	0.061266
DepDelay	0.004769	0.005289	0.008538	0.139254	0.058875	-0.053024	0.053706	0.051852
Distance	0.005498	0.000117	0.008138	-0.056003	-0.029517	-0.027751	0.024335	-0.356770
Diverted	0.006467	0.001190	-0.001361	-0.004632	-0.009096	-0.007204	0.000907	-0.002885

	Month	DayofMonth	DayOfWeek	DepTime	CRSDepTime	ArrTime	CRSArrTime	FlightNum
CarrierDelay	0.000420	-0.000947	0.010215	-0.051948	-0.107337	-0.083981	-0.096156	0.055712
WeatherDelay	0.006611	0.000916	0.005654	0.005307	-0.009338	-0.029860	-0.005033	0.067488
NASDelay	0.011441	0.005644	-0.006628	0.022530				